

# Makine Öğrenmesi

8. hafta


- Haritalama Kavramı
- Çapsal Tabanlı Fonksiyon (RBF)
- RBF Ağları

Yrd. Doç. Dr. Umut ORHAN

1

## Haritalama

Sınıflandırma için olası en iyi durum, iki ayrı sınıfa ait veri noktalarının doğrusal olarak ayrılabilmesi durumudur. Fakat gerçek veri kümelerinde bu her zaman mümkün olmayabilir.



Yrd. Doç. Dr. Umut ORHAN

2

## Haritalama


Önerilen makine öğrenmesi yöntemlerinin hepsi doğrusal sınıflandırmadan yola çıkarak geliştirildiği için doğrusal olmayan veri için çözüm bulamazlar. Örnekleri kendi uzaylarında çözmek yerine veri, sınıfların doğrusal olarak ayrılabilceği yeni bir üst uzaya taşınarak çözülür. Bu işleme haritalama (mapping) adı verilir.

Yrd. Doç. Dr. Umut ORHAN

3

## Haritalama

Genellikle bir  $\Phi$  fonksiyonu doğrusal olarak ayrılamayan  $x$  özellik değerlerini doğrusal olarak ayrılabilir şekle getirir.



Yrd. Doç. Dr. Umut ORHAN

4

## RBF ile Haritalama

$\Phi$  fonksiyonu RBF (Radial Basis Function) tabanlı ise veriyi temsil ettiği düşünülen merkez noktalar ( $c_j$ ) ile veri noktaları ( $x_i$ ) arasındaki uzaklığın eksponansiyel etkisi hesaplanır.

$$\Phi(x) = \exp\left(-\frac{\|c_j - x_i\|^2}{2r^2}\right)$$

## RBF Ağları

Gizli katmandaki nöronlar, girişten ağırlıksız olarak gelen veri noktası  $x_i$  ile nöronda saklı prototip  $c_j$  arasındaki vektörel uzaklığı genellikle Öklit ölçütünü kullanarak hesaplar.

$$d = \|c_j - x_i\|$$


Daha sonra bu uzaklığı çapsal tabanlı fonksiyon ile değerlendirirler.

## RBF Ağları

En sık kullanılan çapsal tabanlı fonksiyon denklemi ve uzaklık-fonksiyon çıktısı grafiksel ilişkisi aşağıda gösterilmiştir.

$$\Phi(x) = \exp\left(-\frac{\|c_j - x_i\|^2}{2r^2}\right)$$


$r$  değeri prototipin çapını ifade eder.



Yrd. Doç. Dr. Umut ORHAN

7

## RBF Ağlarında Mimari



Yrd. Doç. Dr. Umut ORHAN

8

## RBF Ağlarında Tahmin


Hedef sınıfı temsil eden  $y$  değeri, girişi temsil eden  $x$  değerleri üzerinden aşağıdaki denklemle hesaplanır.

$$y_j = \sum_{1 \leq i \leq K} w_i \Phi(x_j)$$


$K$  değeri gizli katmandaki nöron sayısıdır.

## RBF Ağlarının Yapısı

Gizli ve çıkış katmanlarında kullanılan nöron modelleri şekillerde gösterilmektedir.



Gizli katman nöronu



Çıkış katmanı nöronu



## RBF Ağlarının Özellikleri

- Çapsal tabanlı fonksiyon (RBF) ağları eğitici öğrenme yapan ileri beslemeli ağlardır.
- Genel olarak her biri RBF fonksiyonu içeren nöronlardan oluşan tek gizli katman kullanılır.
- Eğitimleri geri-yayıma benzer olsa da MLP ağlarından daha hızlı eğitilirler.
- Çapsal tabanlı fonksiyonlar sayesinde durağan olmayan girişlere sahip problemlerden daha az etkilenir.

Yrd. Doç. Dr. Umut ORHAN

11



## RBF Ağlarında Eğitim

Bir RBF ağında bilinmeyen ve eğitim ile öğrenilmesi gereken dört önemli parametre vardır:

- Gizli katmandaki nöron sayısı
- Her nöronun prototip koordinatı
- Her nöronun prototip çapı
- Çıkış ağırlıkları

Yrd. Doç. Dr. Umut ORHAN

12



## RBF Ağlarında Eğitim

Önerilen yöntemlerin çoğunda gizli katmandaki nöron sayısının deneyerek araştırılması gereken bir değişken olduğu belirtilmiştir. Çıkış ağırlıkları doğrusal bir denklemin bileşenleri olduğu için çözümü kolay ve de nöron çıkışlarına bağlıdır. Dolayısıyla eğitimde en önemli nokta nöronlardaki prototiplerin konum ve çap değerlerini bilmeye dayanmaktadır.

Yrd. Doç. Dr. Umut ORHAN

13



## RBF Ağlarında Eğitim

Nöronlarda bulunan prototip konum bilgisi daha önce bahsedilen danışmansız öğrenme yöntemleriyle (K-means gibi) bulunabilir.

- Danışmanlı ve danışmansız iki farklı eğitimin paralel çalışması sayesinde eğitim hızlı da olabilir.
- Danışmansız öğrenme destekli sınıflayıcılar da sınıflandırma doğruluğu her zaman tam danışmanlı öğrenme yöntemlerine göre daha düşüktür.

Yrd. Doç. Dr. Umut ORHAN

14



## RBF Ağlarında Eğitim

Diğer bir öneri de veri kümesi içerisinde rasgele seçilen örneklerin prototip olarak kullanılması ve konum bilgilerinin (sabit tutulması) güncellenmemesidir. Bu durumda çap (varyans) bilgilerinin bilinmesi ve seçilecek örneklerin veri uzayında her bölgeyi iyi temsil etmesi gerekir.



## RBF Ağlarında Eğitim

RBF ağ yapısı incelendiğinde MLP ağ modeliyle bazı benzerlikler fark edilir. Özellikle çıkış katmanındaki doğrusal yapıdaki benzerlik sayesinde RBF ağının eğitiminde geri yayılım algoritmasından yararlanılabilir.

$$E = \frac{1}{2} \sum_j e_j^2 \quad \Delta w_i = -\eta \frac{\partial E}{\partial w_i}$$



## RBF Ağlarında Eğitim

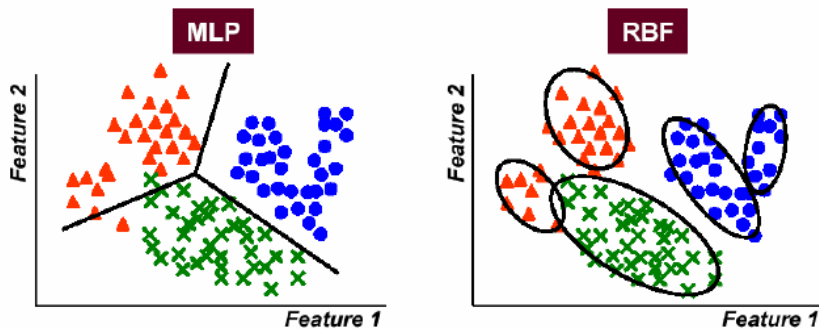
Geri yayılım eğitimiyle çıkış ağırlıkları güncellenir ve gizli katmanda bulunan nöronlardaki fonksiyon çıkışlarındaki güncelleme miktarları öngörülebilir. Bu da dolaylı olarak prototip koordinatları ve prototip çap değerlerinin güncellenmesinde kullanılabilir.

$$\Delta c_i = -\eta \frac{\partial E}{\partial c_i} \quad \Delta r_i = -\eta \frac{\partial E}{\partial r_i}$$

Yrd. Doç. Dr. Umut ORHAN

17

## RBF Ağıyla Sınıflandırma



Yrd. Doç. Dr. Umut ORHAN

18



## ÖDEV

Doğrusal olarak ayrılamayan 2 boyutlu yapay bir veri kümesi için aşağıdaki haritalama fonksiyonlarının arkasından doğrusal regresyonla sınıflandırma yaparak başarıları karşılaştırınız.

- Sigmoid
- Hiperbolik Tanjant
- RBF
- 3. dereceden bir polinom